

Caso fuga

Taller de Ética

Estudiantes: Fernando Miranda Renata Fuentealba Kattia Postigo Luis Figueroa

Profesores:
Pablo Muñoz
Richard Weber

Auxiliares: Joaquín Roa Patricio Ortiz Sofía Pontigo

Fecha de entrega: 6 de junio del 2023

1. Resumen del proyecto

1.1. Contexto

El instituto de Sistemas Complejos de Ingeniería (ISCI) de la Universidad de Chile, es una entidad que se dedica a analizar y generar nuevos conocimientos al resolver problemas de compañías y organizaciones del mundo. En particular, en temas asociados a la Ciencia de Datos, Gestión de Operaciones, Ingeniería de Transporte, Ingeniería de Sistemas de Energía, entre otros.

En el marco del curso de Ciencia de los Datos, el ISCI, ha generado un Caso de Estudio de Fuga de Clientes de un banco, para enseñar y desarrollar en los alumnos conocimientos en sistemas de predicción a través del uso de datos, en este caso, de predicción de fuga de clientes en un banco.

Los bancos son instituciones financieras dedicadas a proveer servicios relaciones a crédito, inversión y asesoría financiera. Su negocio esta asociado a dos aristas, por un lado, la captación de clientes, y por otro la retención de estos. La captación se realiza a través de la incorporación de nuevos segmentos objetivos, mediante la elaboración y ejecución de estrategias de marketing y publicidad. Por controlado, la retención se realiza a través del diseño y aplicación de políticas comerciales que eviten que los clientes se fuguen.

Es importante, conocer previamente que es una fuga, esta corresponde a un acto donde un cliente, de forma espontánea y voluntaria, termina su relación con el banco, cerrando alguno de sus productos cuenta corriente, linea de crédito, inversiones, entre otros.

1.2. Problema Abordado

El banco ABC, enfrentó en el año 2004, una compleja situación económica, asociada a la fuga de clientes de su cartera. La razón: múltiples factores que en su conjunto ocasionaban un incremento en el numero de clientes que dejaban la compañía, algunos de estos factores corresponden a un aumento de campañas de captación de clientes por parte de la competencia, políticas de retención no efectivas y deficientes métricas de la calidad de servicio entregado.

Si bien, se pueden captar nuevos clientes, las costosas campañas de captación, son nocivas a largo plazo, dado que aumentan el riesgo de la cartera, al incorporar clientes con alta probabilidad de fuga (más que un cliente antiguo). Además captar un cliente nuevo tiene un costo 5 a 6 veces mayor que retener uno antiguo, por tanto, el enfoque es estudiar, analizar y predecir la acción de fuga, para generar recomendaciones estratégicas al banco.

Un estudio realizado por el Banco central Europeo, cuantifica los beneficios de disminuir la fuga

de clientes, declarando que si ese banco disminuyera en un 1 % la fuga, se obtendría una utilidad de 33 millones de euros a 25 años plazo. En el caso del banco ABC, se tiene una fuga anual del 10 %, donde uno de los factores preponderantes para esa situación es la calidad del servicio recibido, mas aun, cerca de un 60 % de los clientes realizaron al menos un reclamo, en los 3 meses previos a su fuga.

1.3. Objetivos

Tomando en consideración el problema mencionado anteriormente, el presente proyecto tiene como objetivo implementar técnicas de Machine Learning para generar varios modelos predictivos del problema de fuga, para luego elegir aquel que se desempeñe de mejor manera.

Para lograr esto, se realizarán los siguientes objetivos específicos:

- Analizar datos históricos: Analizar datos relevantes relacionados con la fuga de clientes en el banco ABC.
- Preprocesamiento de datos: Realizar la limpieza y transformación de los datos recopilados, lo
 que puede incluir el manejo de datos faltantes, la normalización de variables, la codificación
 de variables categóricas, entre otros.
- Selección de características relevantes: Identificar las variables más relevantes que influyen en la fuga de clientes, utilizando técnicas de selección de características o análisis exploratorio de datos.
- Diseño y entrenamiento de modelos predictivos: Implementar diferentes técnicas de Machine Learning, como árboles de decisión, regresión logística, Random Forest, redes neuronales u otros algoritmos, para construir modelos predictivos de fuga de clientes. Ajustar los hiperparámetros de los modelos y evaluar su rendimiento utilizando métricas apropiadas, como precisión, recall, F1-score, entre otras.
- Comparación y selección del mejor modelo: Evaluar y comparar el rendimiento de los diferentes modelos desarrollados, seleccionando el modelo que demuestre el mejor desempeño en términos de precisión y capacidad predictiva.
- Generación de recomendaciones estratégicas: Utilizar el modelo seleccionado para predecir la fuga de clientes y analizar los factores que influyen en esta predicción. A partir de estos resultados, proporcionar recomendaciones estratégicas al banco ABC, como mejoras en las políticas de retención, optimización de la calidad del servicio y desarrollo de acciones de fidelización.

1.4. Descripción de la base de datos

La base de datos proporcionada por el banco ABC es un registro con 18 columnas/atributos y 1386 observaciones, de las cuales 1248 corresponden a datos de entrenamiento y 138 de validación.

Esta base de datos está compuesta principalmente por 3 grupos de variables. La primera tabla almacena todas las variables de comportamiento transaccional bancario, como saldos, transacciones por los diferentes canales y utilización de productos, entre otras. Estas variables son almacenadas en cada mes teniéndose para cada una de ellas una serie de tiempo. Con esto último se captura el comportamiento dinámico del cliente dentro de la compañía. La segunda tabla almacena las características sociodemográficas de los clientes, como la edad, género, estado civil y nivel educacional. La tercera tabla almacena los reclamos y amenazas de cierre de productos realizados por los clientes de forma mensual.

Es importante mencionar que la información no está exente de errores e inconsistencias. Se han encontrado campos con valores perdidos y otros anómalos. Además, es sabido que esta base de datos no está pensada originalmente para la realización de un sistema de detección temprana de fugas. Por este motivo, algunas variables no pueden utilizarse directamente en la base de datos original.

Las columnas/variables son las siguientes: : Cod_Cliente(Código del cliente), COM(Código comuna), ED(Edad), SX(Sexo), NIV_EDUC(Nivel educacional), RENTA, E_CIVIL(Estado civil), VIG(Vigencia del contrato), TRX_T(Cantidad de transacciones realizadas en tiempo T), TRX_T-i[i=1,2](Cantidad de transacciones realizadas en tiempo T-i), SALDO_T(Saldo que tiene el cliente en la cuenta en tiempo T), SALDO_T-i[i=1-5](Saldo que tiene el cliente en la cuenta en tiempo T-i) y CERRO(Indica si el cliente cerró o no la cuenta).

2. Herramienta elaborada

Se desarrolla una herramienta que permite evaluar el cumplimiento de los principios éticos fundamentales en el ámbito del análisis de datos, a través de un enfoque basado en 4 dimensiones éticas clave. Rosa Colmenarejo, Doctora en Ciencias Jurídicas y Sociales, pone de relieve la relevancia de la identidad, la toma de decisiones éticas en el manejo de los datos, y las posibles infracciones a la privacidad que pueden surgir en este campo científico[1]. Dada la importancia de estos aspectos, se opta por emplear las siguientes dimensiones del quehacer profesional:

- Calidad de los datos
- Seguridad y confidencialidad
- Uso de los datos
- Relación con el mandante

El proceso de evaluación se basa en una escala numérica del 1 al 10, donde los valores se asignan a cada dimensión. A continuación se presentan los puntos de referencia que representan la importancia relativa de cada categoría en la escala:

Tabla 1: Importancia relativa de cada categoría en la escala

Puntaje	Categoría				
1	No cumple con la dimensión en absoluto				
5	Valor neutral				
10	Cumple perfectamente con la dimensión				

La determinación de la evaluación se lleva a cabo de acuerdo con el siguiente procedimiento: en primer lugar, se obtiene una puntuación para cada principio ético, que se calcula como el promedio de las puntuaciones de cada dimensión del principio correspondiente. De esta manera, se puede analizar la calidad ética del proyecto en relación con cada principio. La puntuación final del proyecto se calcula como el promedio de las puntuaciones de cada principio ético. Sea P el conjunto de principios, y D el conjunto de dimensiones, las calificaciones de los principios estarán dadas por:

$$NP_i = \frac{1}{|D|} \sum_{j \in D} ND_{i,j} \tag{1}$$

donde, NP_i es la nota del principio $i \in P$ y $ND_{i,j}$ es la nota para la dimensión $j \in D$ con respecto al principio i. Con esto se puede calcular la nota final del proyecto como:

$$N_{final} = \frac{1}{|P|} \sum_{i \in P} NP_i \tag{2}$$

Para cumplir con los requerimientos éticos mínimos se debe alcanzar un 60% de la calificación máxima obtenible, es decir, un promedio de 6 puntos de un máximo de 10. Además, se debe lograr al menos una calificación neutra en cada dimensión ética analizada. En otras palabras, que el puntaje total alcanzado a nivel de cada principio ético sea de al menos el 50% del puntaje máximo lograble, es decir, de un mínimo de 5. La justificación de esta propuesta está fundamentada en los siguientes argumentos:

- La idea fundamental de cualquier práctica ética es prevenir daño. Por lo tanto, cualquier proyecto que no alcance la calificación mínima en cualquier dimensión ética es potencialmente perjudicial en esa dimensión. No es ético permitir la realización de proyectos que tienen la certeza de causar daño.
- En cualquier proyecto, todas las dimensiones éticas son importantes y no se pueden ignorar. Por lo tanto, se requiere un puntaje mínimo en todas las dimensiones, para asegurar que todas las consideraciones éticas hayan sido tomadas en cuenta.
- Este sistema de evaluación proporciona un equilibrio entre la evaluación cuantitativa y cualitativa de los principios éticos. Mientras que la calificación cuantitativa proporciona un marco de evaluación estandarizado, la calificación mínima para cada dimensión asegura que los aspectos cualitativos de la ética no se ignoren.

- La exigencia de un mínimo de 6 puntos en el promedio total asegura que los proyectos cumplen con más de la mitad de las expectativas éticas, lo cual es un requisito razonable para garantizar que se cumplan las normas éticas fundamentales.
- Este sistema de evaluación también proporciona un marco para la rendición de cuentas y la transparencia. Al asignar puntajes a diferentes principios y dimensiones éticas, se hace posible identificar y corregir deficiencias específicas.

Estas justificaciones proporcionan una base sólida para la aplicación de este sistema de evaluación y ayudarán a garantizar que todos los proyectos cumplan con los más altos estándares éticos.

2.1. Principios éticos a evaluar

Según el "Data Ethics Framework 2020" de la Oficina Central Digital y de Datos del Gobierno de UK[2], existen tres principios éticos fundamentales que deben ser aplicados al uso de datos: la transparencia, la rendición de cuentas y la equidad. La transparencia se refiere a la necesidad de que las organizaciones sean claras y abiertas sobre cómo utilizan los datos y cómo toman decisiones basadas en ellos mientras que la rendición de cuentas se refiere a la necesidad de que las organizaciones sean responsables y puedan ser evaluadas por sus acciones y decisiones en relación con los datos. Por último, la equidad se refiere a la necesidad de que los datos se utilicen de manera justa y sin discriminación, teniendo en cuenta las diferencias entre las personas y sus necesidades e intereses.

Además, se considera el principio de beneficencia, que provienen del campo de la bioética y se ha extendido a otros contextos éticos. La beneficencia se basa en la obligación moral de actuar en beneficio de los demás y promover el bienestar. En términos generales, la beneficencia implica tomar acciones positivas para maximizar los beneficios y minimizar los daños potenciales.

En resumen, al desarrollar este proyecto, se consideran los principios éticos de transparencia, rendición de cuentas, equidad, beneficencia.

2.2. Dimensiones éticas del quehacer profesional

Las dimensiones éticas del quehacer profesional se refieren a los aspectos éticos y morales que deben guiar la conducta y las decisiones de los profesionales en el ejercicio de su trabajo. Estas dimensiones éticas son consideradas fundamentales para garantizar un desempeño ético y responsable en cualquier campo profesional. Las dimensiones a considerar son calidad de los datos, la seguridad y confidencialidad de los datos, el uso de estos y la relación con el mandante.

Se busca relacionar los principios éticos de transparencia, rendición de cuentas, equidad y beneficencia con las dimensiones éticas de calidad de los datos, seguridad de los datos y confidencialidad, uso de los datos y relación con el mandante. A continuación, se presenta una explicación detallada de cada dimensión ética y su relación con los principios éticos correspondientes:

1. Transparencia

- Calidad de los datos: se relaciona con la transparencia en la forma en que se recolectan, procesan y presentan. La transparencia implica que los datos sean recopilados y analizados de manera clara y objetiva, evitando sesgos y manipulaciones.
- Seguridad y confidencialidad de los datos: implica la transparencia en la forma en que se protegen y gestionan. Los profesionales deben garantizar que los datos estén protegidos contra accesos no autorizados y que se utilicen medidas adecuadas para salvaguardar la privacidad y la confidencialidad de la información.
- Uso de los datos: requiere transparencia en cómo se utilizan y se toman decisiones basadas en ellos. Los profesionales deben proporcionar información clara y comprensible sobre el uso previsto de los datos, evitando usos indebidos o no éticos.
- La relación con el mandante: requiere transparencia en la comunicación y el intercambio de información. Los profesionales deben ser transparentes en la forma en que interactúan con el mandante, asegurando que se comparta la información relevante de manera clara y comprensible.

2. Rendición de cuentas:

- Calidad de los datos: Implica la responsabilidad de los profesionales de garantizar
 que los datos sean precisos, confiables y verificables. La rendición de cuentas implica que
 los profesionales deben poder justificar y explicar los métodos utilizados para recopilar
 y validar los datos, asegurando su calidad.
- Seguridad y confidencialidad de los datos: Requieren que los profesionales sean responsables de implementar y mantener medidas de seguridad adecuadas. Además, deben rendir cuentas sobre las prácticas y políticas de seguridad implementadas, demos trando su compromiso con la protección de los datos.
- Uso de los datos: La responsabilidad de los profesionales de utilizarlos de manera ética y responsable, asegurándose de que las decisiones basadas en los datos sean fundamentadas y justificables. Los profesionales deben rendir cuentas por las decisiones tomadas y los resultados obtenidos a partir del uso de los datos.
- La relación con el mandante: Implica la responsabilidad de los profesionales de cumplir con los acuerdos y las obligaciones establecidas, brindando un servicio de calidad y actuando en el mejor interés del mandante. Los profesionales deben rendir cuentas por su desempeño y asegurarse de que se cumplan los objetivos y las expectativas del mandante.

3. Equidad

- Calidad de los datos: implica la responsabilidad de los profesionales de garantizar que los datos sean precisos, confiables y verificables.
- Seguridad y confidencialidad de los datos: requieren que los profesionales sean responsables de implementar y mantener medidas de seguridad adecuadas. Además, deben rendir cuentas sobre las prácticas y políticas de seguridad implementadas, demostrando su compromiso con la protección de los datos.
- Uso de los datos: la responsabilidad de los profesionales de utilizarlos de manera ética y responsable, asegurándose de que las decisiones basadas en los datos sean fundamentadas y justificables. Los profesionales deben rendir cuentas por las decisiones tomadas y los resultados obtenidos a partir del uso de los datos.
- La relación con el mandante: implica la responsabilidad de los profesionales de cumplir con los acuerdos y las obligaciones establecidas, brindando un servicio de calidad y actuando en el mejor interés del mandante. Los profesionales deben rendir cuentas por su desempeño y asegurarse de que se cumplan los objetivos y las expectativas del mandante.

4. Beneficencia

- Calidad de los datos: Incluye la obligación de ayudar a otros a promover sus importantes y legítimos intereses, esto significa que los profesionales tienen la responsabilidad de garantizar que los datos se utilicen de manera beneficiosa para la empresa y que se tomen decisiones basadas en ellos que promuevan los intereses de la empresa y garantizar que los modelos de machine learning sean precisos y útiles para la toma de decisiones empresariales.
- Seguridad y confidencialidad de los datos: Al proteger los datos contra accesos no autorizados y utilizar medidas adecuadas para salvaguardar la privacidad y la confidencialidad de la información, los profesionales pueden garantizar que los datos se utilicen de manera beneficiosa para la empresa.
- Uso de los datos: Establecer reglas claras para la gestión de datos: La gobernanza de datos es esencial para garantizar que los datos se utilicen de manera beneficiosa para la empresa.
- La relación con el mandante: Planificar el incremento de beneficios y la reducción del riesgo. Los investigadores y miembros de sus instituciones están obligados a planificar el incremento de beneficios y la reducción del riesgo que pudiera ocurrir como resultado de la investigación. Esto implica considerar tanto los posibles beneficios como los posibles riesgos de la investigación, y tomar medidas para maximizar los beneficios y minimizar los riesgos.

3. Implementación y uso de la herramienta

A continuación se detallan las evaluaciones de cada una de las dimensiones éticas y se justifican:

Figura 1: Implementación de la herramienta.

Transparencia				Promedio	Promedio Final
Calidad de los datos	Seguridad y confidencialidad	Uso de los datos	Relación	7	
6	8	9	5		
Rendición de cuentas				Promedio	
Calidad de los datos	Seguridad y confidencialidad	Uso de los datos	Relación	6,5	
6	5	9	6		
					7
Equidad				Promedio	,
Calidad de los datos	Seguridad y confidencialidad	Uso de los datos	Relación	7,25	
8	8	6	7		
Beneficiencia				Promedio	
Calidad de los datos	Seguridad y confidencialidad	Uso de los datos	Relación	7,25	
9	5	10	5		

1. Transparencia

- Calidad de los Datos (6): A pesar de que el banco ABC entregó los datos de manera oportuna, se identificaron algunas limitaciones significativas en cuanto a la cantidad y consistencia de los datos proporcionados. No obstante, se encontró que los datos estaban acompañados de un diccionario que ofrecía una explicación precisa de las variables que contenían.
- Seguridad y confidencialidad de los datos (8): Los datos proporcionados se encontraban debidamente anonimizados, lo cual garantiza la protección de la privacidad de los clientes del banco. No se dispone de información sobre el nivel de conocimiento que tienen los clientes respecto al uso de sus datos.
- Uso de los datos (9): Durante el desarrollo del proyecto los datos fueron usando correctamente y esto fue indicado en el informe correspondiente. En ningún momento se incurrió en un uso indebido o no ético de los mismos.
- Relación con el mandante (5): Dado el contexto del proyecto desarrollado, no existió relación con el mandante.

2. Rendición de cuentas

■ Calidad de los Datos (6): Al ser un Data warehouse corporativo, las fuentes de información y métodos de recopilación son en su mayoría sólidos y están respaldados por procesos adecuados de validación. Posee un registro histórico de datos. Sin embargo, la data posee varios datos nulos y outliers, por lo que la data no es de tan buena calidad.

- Seguridad y confidencialidad de los datos (5): Dado que se están analizando datos sensibles de los clientes, es crucial que el banco implemente medidas sólidas de seguridad y confidencialidad para proteger la información. Sin embargo, no se especifican prácticas de seguridad implementadas, como el uso de protocolos de seguridad, como el cifrado de datos, firewalls y acceso restringido a la información. Pero, sí se protege la confidencialidad de los clientes al utilizar un código de clientes".
- Uso de los datos (9): El banco utiliza los datos recopilados de manera ética y responsable para comprender las causas de la fuga de clientes y tomar decisiones fundamentadas para abordar el problema.
- Relación con el mandante (6): El banco debería cumplir con los acuerdos y las obligaciones establecidas con sus clientes, pero en este caso no se está brindando un servicio completo de calidad. Sin embargo, se están tomando medidas para retener a los clientes y abordar sus preocupaciones. El banco debe rendir cuentas por su desempeño y trabajar en el mejor interés de sus clientes.

3. Equidad

- Calidad de los datos (8): La metodología utilizada para la generación de modelos en conjunto con la base de datos como tal, no da lugar a discriminaciones de ningún tipo.
- Seguridad y confidencialidad de los datos (8): El proceso utilizado, si bien no tiene protocolos directos de seguridad, si está realizado sobre una base sin identificadores que permitan rastrear al originador de cada punto de dato, sumado a eso, todos tenemos acceso a la base, por tanto, no hay acciones discriminatorias asociadas.
- Uso de los datos (6): Durante el desarrollo del proyecto y el trabajo con los datos, se realiza de manera ética y responsable, asegurando decisiones fundamentadas.
- Relación con el mandante (7): Dado el marco del curso, queda establecido el rol de cada integrante, del equipo docente, y el de los datos, por tanto, todos están en conocimiento del estado del proyecto y no hay discriminación de ningún tipo.

4. Beneficencia

- Calidad de los datos (9) Se llevaron a cabo diversas acciones para asegurar que la calidad de los datos se mantuviera, o bien, mejorarán con la finalidad de entregar un buen modelo predictor y que la información sea útil para el mandante.
- Seguridad y confidencialidad de los datos (5) La base de datos fue proporcionada para todo los integrantes del curso por lo que no se puede asegurar que dicha base de datos no haya sido compartida en otros espacios y que esto pueda perjudicar al banco.
- Uso de los datos (10) Se llevó a cabo una correcta gestión de los datos para lograr el objetivo encomendado para el banco.
- Relación con el mandante (5) Debido a que no se tiene contacto directo con el mandante se tiene solo el objetivo general y no se realiza un análisis en conjunto.

4. Discusión y conclusiones

4.1. Evaluación del proyecto

En el campo del machine learning, además de evaluar la eficacia y precisión de un proyecto, también es fundamental considerar su aspecto ético. En este contexto, este comentario se enfocará en analizar la calificación ética de 7 otorgada a un proyecto específico de machine learning, cuyo objetivo es predecir resultados. Si bien esta calificación indica que el proyecto tiene un nivel aceptable en términos éticos, existe espacio para mejorarlo y garantizar que cumpla con los más altos estándares éticos posibles.

La evaluación de la relación con el mandante se encuentra actualmente en un estado crítico o bajo. Esto se debe, en gran parte, al contexto particular del proyecto que ha limitado completamente la posibilidad de establecer y mantener una comunicación eficaz y un enlace significativo con el mandante. La naturaleza del proyecto ha generado una dinámica en la que la interacción directa y constante se ha visto obstaculizada, afectando así la evaluación en esta dimensión. Otro aspecto que se ve afectado debido al contexto del proyecto es el uso y la seguridad de los datos, pues al ser utilizados en un contexto académico, la seguridad de estos es menor en comparación a la seguridad que tendrían en un contexto profesional.

En cuanto a la calidad de los datos, se propone la capacitación del personal y promover la conciencia sobre la importancia de la calidad de los datos en todos los niveles de la organización. Esto ayuda a garantizar que todos los involucrados entiendan la relevancia de mantener datos de alta calidad.

4.2. Desempeño de la herramienta

En relación con la herramienta desarrollada, se puede concluir que su capacidad satisface las necesidades para la evaluación ética de proyectos dentro del ámbito de los datos. La escala numérica adoptada para las métricas facilita una evaluación más precisa y de mayor alcance.

Al llevar a cabo una evaluación basada en principios y posteriormente realizar una agregación de los resultados, podemos analizar tanto las fortalezas como las debilidades del proyecto con respecto a cada uno de los principios éticos. No obstante, la formulación matemática empleada asigna una ponderación uniforme a través de los principios, es decir, otorga la misma importancia a cada uno de ellos en la evaluación. Este enfoque limita la flexibilidad de la evaluación, ya que dependiendo del proyecto y del contexto en el que se encuentre, la valoración de un principio podría tener más peso que otro.

Teniendo esto en cuenta, una mejora potencial para la herramienta sería la incorporación de ponderadores para cada uno de los principios, de manera que la calificación final del proyecto sea un promedio ponderado de las notas obtenidas en cada principio. De este modo, la métrica mostraría

una mayor adaptabilidad al contexto específico de cada proyecto.

Otro factor importante a considerar es que se aplicaron las mismas dimensiones a todos los principios éticos, lo cual restringe la capacidad para analizar cada principio de una manera más detallada y exhaustiva. Tomando en cuenta este aspecto, se sugiere una mejora para la herramienta que implicaría la utilización de dimensiones diferenciadas para cada uno de los principios, las cuales serían más pertinentes y acordes a las características específicas de estos principios.

Referencias

- [1] Colmenarejo, R. (n.d.). Colmenarejo Fernández, Rosa (2017). UNA ÉTICA PARA BIG DATA Introducción a la gestión ética de datos masivos. Prólogo de Marta Pedrajas. Barcelona: Editorial UOC.
- [2] Data Ethics Framework. (2020, September 30). GOV.UK.. [Consultado el 6 de junio del 2023]. Disponible en línea: https://www.gov.uk/government/publications/data-ethics-framework/data-ethics-framework-2020